Prédiction des Prix Immobiliers en Californie

SAAOUD Safae, ZOUAK Douak & SAAYDI Aicha
Ingénerie Logiciel et Intelligence Artificielle
École Nationale des Sciences Appliquées
Fès, Maroc

***Résumé*—Cet article présente une étude comparative exhaustive de modèles de machine learning pour la prédiction des prix immobiliers en Californie. En utilisant le jeu de données California Housing, nous évaluons systématiquement plusieurs architectures : régression linéaire, k-plus-proches voisins (KNN), forêt aléatoire (Random Forest) et perceptron multicouches (MLP). Une étape cruciale d'ingénierie des caractéristiques est mise en œuvre pour extraire des relations implicites entre variables, incluant la création d'une caractéristique géographique synthétique (GeoAxis) et de ratios démographiques significatifs. Après optimisation rigoureuse des hyperparamètres via recherche aléatoire et validation croisée, le modèle Random Forest démontre la meilleure performance avec un coefficient de détermination $R^2 = 0.8210$ et une erreur absolue moyenne $MAE = 0.3084$ sur l'échelle logarithmique. Une analyse approfondie des résidus révèle une hétéroscédasticité persistante, avec des erreurs croissantes pour les propriétés haut de gamme. L'article discute également le déploiement pratique via une interface web interactive développée avec Gradio, permettant des prédictions en temps réel basées sur des caractéristiques utilisateur.**

***Index Terms*—Apprentissage automatique, prédiction immobilière, forêt aléatoire, ingénierie des caractéristiques, optimisation d'hyperparamètres, régression.**

I. Introduction

LA prédiction des prix immobiliers constitue un problème de régression fondamentale en apprentissage automatique, avec des implications économiques et sociales substantielles. La complexité inhérente à ce domaine provient de la multiplicité des facteurs influençant la valeur des propriétés : caractéristiques structurelles, localisation géographique, indicateurs socio-économiques et dynamiques de marché. Le jeu de données California Housing, dérivé du recensement américain de 1990, offre un cadre standardisé pour évaluer et comparer des algorithmes de prédiction dans un contexte réaliste.

Les principaux défis méthodologiques incluent :

1) la gestion de l'hétéroscédasticité, où la variance des erreurs augmente avec la valeur des propriétés.
2) la modélisation de relations non-linéaires complexes entre caractéristiques.
3) l'extraction de caractéristiques informatives à partir de données limitées.
4) la sélection objective du modèle optimal parmi des architectures concurrentes.

Cet article contribue à la littérature en présentant une comparaison systématique de cinq approches de modélisation, depuis les méthodes de base jusqu'aux architectures complexes, en mettant l'accent sur une évaluation rigoureuse et reproductible.

Notre méthodologie intègre un pipeline complet d'ingénierie des caractéristiques, d'optimisation des hyperparamètres et de validation, aboutissant au déploiement d'une application de prédiction interactive.

II. Formulation du Problème

A. Jeu de Données

Le dataset California Housing contient 20 640 échantillons représentant des districts résidentiels en Californie. Chaque échantillon comprend 8 caractéristiques prédictives et une variable cible continue (MedHouseVal), exprimée en centaines de milliers de dollars. Les caractéristiques incluent des indicateurs démographiques (revenu médian, population), structurels (âge des maisons, nombre de pièces) et géographiques (latitude, longitude).

B. Formalisation Mathématique

Soit $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ l'ensemble des données, où $\mathbf{x}_i \in \mathbb{R}^d$ représente le vecteur de caractéristiques et $y_i \in \mathbb{R}$ la valeur cible. Le problème de régression consiste à apprendre une fonction $f : \mathbb{R}^d \to \mathbb{R}$ minimisant l'erreur de prédiction :

$$\mathcal{L}(f) = \frac{1}{N} \sum_{i=1}^{N} \ell(y_i, f(\mathbf{x}_i))$$

où ℓ est une fonction de perte (par exemple, l'erreur quadratique moyenne).

1) Prétraitement de la Variable Cible

La distribution de la variable cible y (MedHouseVal) présente une asymétrie droite significative, quantifiée par son coefficient d'asymétrie (skewness) :

$$\text{Skew}(Y) = \frac{\mathbb{E}[(Y-\mu)^3]}{\sigma^3} = 0.98$$

où μ et σ représentent respectivement la moyenne et l'écart-type de Y. Une valeur de skewness proche de zéro indique une distribution symétrique (normale), tandis qu'une valeur positive supérieure à 0.5 suggère une asymétrie droite substantielle, avec une queue de distribution étendue vers les valeurs élevées.

Pour atténuer cette asymétrie et se rapprocher des hypothèses de normalité sous-jacentes à de nombreux modèles de

régression (notamment la régression linéaire), nous appliquons une transformation logarithmique de type log1p :

$$\tilde{y} = \log(1 + y)$$

Cette transformation présente deux avantages principaux :

1) Elle réduit fortement l'asymétrie (la skewness passe de 0.97 à environ 0.27), rendant la distribution quasi-symétrique.
2) Elle stabilise la variance des résidus, atténuant ainsi le phénomène d'hétéroscédasticité où la variance des erreurs croît avec la valeur de la cible.

La transformation inverse permettant de revenir à l'échelle originale des prix est donnée par :

$$y = \exp(\tilde{y}) - 1$$

2) *Prétraitement des Caractéristiques*

Le même principe est appliqué aux caractéristiques prédictives présentant une asymétrie marquée. Nous calculons systématiquement le coefficient d'asymétrie pour chaque caractéristique et appliquons la transformation log1p lorsque $\text{Skew}(X) > 1.0$. Par exemple, les variables *Population* et *AveOccup* présentent initialement des skewness respectives de 4.93 et 97.63, qui sont réduites à des valeurs proches de zéro après transformation. Cette normalisation des distributions améliore la performance des modèles sensibles à l'échelle et à la forme des distributions, tels que KNN et les réseaux de neurones, et accélère la convergence des algorithmes d'optimisation.

C. *Métriques d'Évaluation*

Les performances des modèles sont évaluées sur l'échelle originale des prix après application de la transformation inverse $y = \exp(\tilde{y}) - 1$. Cette approche garantit que les erreurs sont interprétables en unités monétaires réelles (centaines de milliers de dollars). Trois métriques complémentaires sont employées pour une évaluation multidimensionnelle :

1. Racine de l'Erreur Quadratique Moyenne (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}$$

Cette métrique pénalise quadratiquement les erreurs importantes, offrant une mesure de l'écart-type des erreurs de prédiction.

2. Erreur Absolue Moyenne (MAE)

$$\text{MAE} = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|$$

Plus robuste aux valeurs aberrantes que la RMSE, la MAE exprime l'erreur de prédiction moyenne en valeur absolue.

3. Coefficient de Détermination (R^2)

$$R^2 = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2}$$

Cette statistique mesure la proportion de variance expliquée par le modèle, où $\bar{y} = \frac{1}{N}\sum_{i=1}^{N} y_i$. Un R^2 proche de 1 indique une excellente capacité prédictive, tandis qu'un R^2 nul correspond à un modèle ne surpassant pas la simple prédiction par la moyenne.

III. Méthodologie

A. *Architecture du Pipeline*

Notre approche suit un pipeline standard de machine learning, illustré à la Fig. 1 :

FIGURE 1. Pipeline de traitement des données et modélisation.

B. *Ingénierie des Caractéristiques*

L'étape d'ingénierie des caractéristiques vise à extraire des relations informatives non directement présentes dans les données brutes. Nous créons 10 caractéristiques supplémentaires, portant la dimension totale à 18.

1) *Caractéristique Géographique Synthétique (GeoAxis)*

L'analyse de la matrice de corrélation (Fig. 2) a révélé que la latitude et la longitude présentent des relations distinctes mais complémentaires avec le prix des logements. Plutôt que de traiter ces coordonnées comme des caractéristiques indépendantes, nous les combinons en une seule caractéristique synthétique via une régression linéaire auxiliaire :

$$\text{GeoAxis} = \mathbf{w}_g^\top \begin{bmatrix} \text{Latitude} \\ \text{Longitude} \end{bmatrix} + b_g$$

où $\mathbf{w}_g$ et b_g sont les paramètres appris en minimisant l'erreur de prédiction sur les prix logarithmiques. Cette projection unidimensionnelle encode l'effet géographique agrégé et présente une corrélation améliorée avec la variable cible comparée aux coordonnées individuelles.

2) *Transformations Non-Linéaires Guidées par la Distribution*

L'examen des distributions des caractéristiques a identifié plusieurs variables présentant une asymétrie prononcée (skewness > 1.0). Comme le montre la diagonale de la matrice de corrélation incluant les distributions marginales, ces asymétries peuvent nuire aux performances des modèles supposant

une distribution normale des erreurs. Nous appliquons donc une transformation logarithmique stabilisatrice :

$$x_{\log} = \log(1 + x)$$

Cette transformation s'applique particulièrement à *Population* et *AveOccup*, réduisant radicalement leur asymétrie et améliorant leur relation linéaire avec la cible, comme en témoigne l'augmentation des coefficients de corrélation correspondants dans la matrice post-transformation.

3) Ratios et Interactions Dérivés de l'Analyse des Relations

L'examen attentif des corrélations croisées dans la matrice a suggéré des interactions potentielles entre variables. Nous avons ainsi défini des caractéristiques composites qui capturent des relations économiques et démographiques sous-jacentes :

$$\text{Rooms_per_occupant} = \frac{\text{AveRooms}}{\text{AveOccup}}$$

$$\text{Bedrooms_per_room} = \frac{\text{AveBedrms}}{\text{AveRooms}}$$

$$\text{MedInc_times_GeoAxis} = \text{MedInc} \times \text{GeoAxis}$$

— **Rooms_per_occupant** : indique le nombre de personnes par chambre, reflétant le niveau de densité d'occupation dans le logement.

— **Bedrooms_per_room** : quantifie la proportion de chambres utilisées comme chambres à coucher ; lorsque cette proportion augmente (moins de pièces polyvalentes), le prix des maisons tend à être plus élevé.

— **MedInc_times_GeoAxis** : reflète l'effet combiné d'un revenu médian élevé et d'une localisation privilégiée : dans les quartiers aisés où vivent des ménages riches, les prix immobiliers tendent naturellement à être plus élevés.

Ces nouvelles caractéristiques, issues d'une analyse systématique des relations dans les données, contribuent à expliquer des aspects du marché immobilier non capturés par les variables brutes, comme en témoigne l'amélioration significative des performances des modèles après leur inclusion.

C. Préparation des Données

Les données sont partitionnées en ensembles d'entraînement (80%) et test (20%). La normalisation par *StandardScaler* (centrage-réduction) est apprise exclusivement sur l'ensemble d'entraînement pour éviter toute fuite d'information. Toutes les caractéristiques sont transformées pour avoir moyenne nulle et écart-type unitaire.

D. Modèles Évalués

1) Modèle de Référence (Dummy)

Pour établir une baseline minimale de performance, nous implémentons un modèle naïf qui prédit systématiquement la moyenne des prix observée dans l'ensemble d'entraînement :

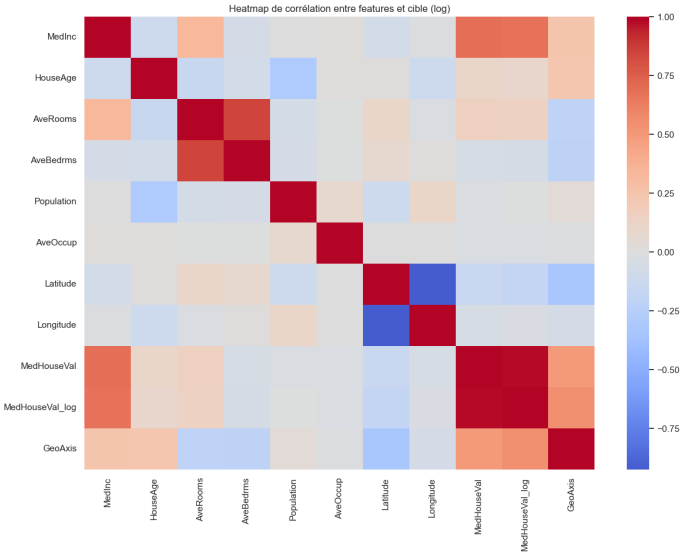

FIGURE 2. Matrice de corrélation et distributions des caractéristiques avant features engineering.

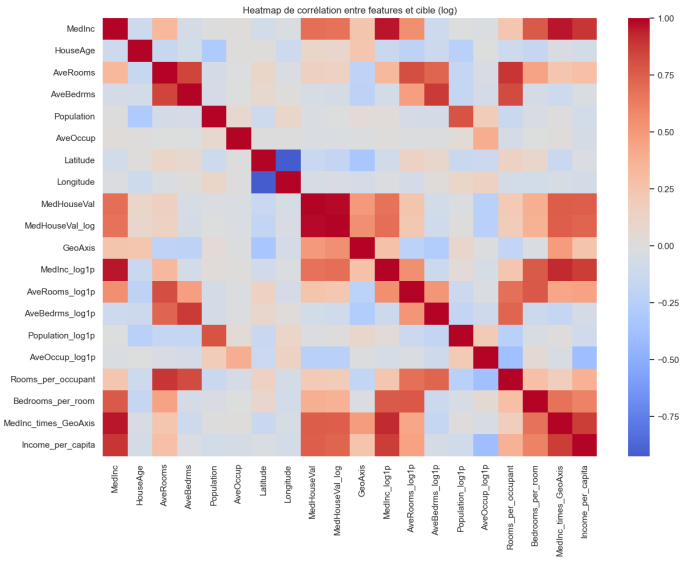

FIGURE 3. Matrice de corrélation et distributions des caractéristiques apres features engineering .

$$\hat{y}_i = \bar{y} = \frac{1}{N_{\text{train}}} \sum_{j \in \text{train}} y_j \quad \forall i$$

Ce modèle Dummy, paramétré avec la stratégie "mean", sert de référence absolue permettant d'évaluer la valeur ajoutée des modèles plus sophistiqués. Toute performance inférieure à cette baseline indiquerait que le modèle est moins informatif que la simple moyenne historique, tandis qu'une performance supérieure démontre une capacité prédictive réelle. Cette approche fournit un point de comparaison essentiel pour évaluer objectivement l'apport des différentes architectures de machine learning.

2) Régression Linéaire (Baseline)

La régression linéaire constitue le modèle de référence pour les problèmes de prédiction continue, établissant une performance de base avec une architecture paramétrique simple. Ce modèle postule l'existence d'une relation linéaire entre les caractéristiques d'entrée et la variable cible :

$$\hat{y} = \mathbf{w}^\top \mathbf{x} + b$$

où $\mathbf{w} \in \mathbb{R}^d$ représente le vecteur des poids associés à chaque caractéristique et $b \in \mathbb{R}$ le terme de biais. Les paramètres sont estimés par minimisation de l'erreur quadratique moyenne via les équations normales ou la descente de gradient. Cette approche fournit non seulement des prédictions mais également des insights interprétables sur l'importance relative des différentes variables via la magnitude des coefficients de régression.

3) K-Nearest Neighbors (KNN)

KNN (K-Nearest Neighbors) est une méthode non-paramétrique fondée sur le principe fondamental de similarité locale. Pour chaque observation à prédire, l'algorithme identifie les k échantillons d'entraînement les plus proches dans l'espace des caractéristiques, selon une métrique de distance spécifiée. La prédiction résulte d'une agrégation des valeurs cibles de ces voisins :

$$\hat{y}_i = \frac{1}{k} \sum_{j \in \mathcal{N}_k(i)} y_j$$

où $\mathcal{N}_k(i)$ désigne l'ensemble des k plus proches voisins. Cette approche repose sur l'hypothèse implicite que des points géométriquement proches dans l'espace des caractéristiques partagent des valeurs cibles similaires. La flexibilité de KNN réside dans son absence de suppositions paramétriques sur la forme de la fonction de régression, permettant ainsi de capturer des relations complexes sans modélisation explicite.

4) Random Forest (RF)

La Forêt Aléatoire est un modèle d'ensemble qui combine les prédictions de multiples arbres de décision indépendants. Contrairement à un arbre unique, cette architecture réduit significativement le risque de surapprentissage tout en capturant des relations non-linéaires complexes grâce au principe de la sagesse des foules (wisdom of crowds). Chaque arbre f_t est entraîné sur un sous-échantillon bootstrap des données d'entraînement, avec une sélection aléatoire de caractéristiques à chaque division de nœud pour assurer la diversité de l'ensemble. La prédiction finale agrège les résultats de tous les arbres par simple moyenne :

$$\hat{y} = \frac{1}{T} \sum_{t=1}^{T} f_t(\mathbf{x})$$

L'optimisation des hyperparamètres constitue une étape essentielle pour maximiser les performances du modèle, car chacun d'eux contrôle un aspect précis de son fonctionnement. Le paramètre **n_estimators** représente le nombre d'arbres dans la forêt : une valeur élevée renforce la stabilité du modèle mais augmente le coût computationnel. Le paramètre **max_depth** fixe la profondeur maximale des arbres ; lorsqu'il est réglé à *None*, les arbres croissent librement jusqu'à ce que toutes les feuilles soient pures ou respectent la contrainte **min_samples_split**. Le paramètre **min_samples_split** correspond au nombre minimal d'échantillons requis pour diviser un nœud interne, influençant directement la granularité de l'arbre. Quant à **max_features**, il définit le nombre de caractéristiques considérées lors de la recherche de la meilleure division ; le réglage *log2* sélectionne $\log_2(d)$ caractéristiques, ce qui permet de réduire la corrélation entre les arbres. Enfin, le paramètre **bootstrap** précise si un échantillonnage bootstrap est utilisé. Lorsqu'il est fixé à *False*, chaque arbre est entraîné sur l'ensemble complet des données.

5) Perceptron Multicouches (MLP)

Le Perceptron Multicouches est une architecture de réseau de neurones artificiels qui modélise des relations complexes via une composition de transformations non-linéaires. Contrairement aux modèles linéaires, le MLP peut apprendre des représentations hiérarchiques des données grâce à ses couches cachées :

$$\begin{aligned} \mathbf{h}_1 &= \text{ReLU}(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1) \\ \mathbf{h}_2 &= \text{ReLU}(\mathbf{W}_2 \mathbf{h}_1 + \mathbf{b}_2) \\ \hat{y} &= \mathbf{w}_o^\top \mathbf{h}_2 + b_o \end{aligned}$$

où $\mathbf{W}_1$, $\mathbf{W}_2$ et $\mathbf{w}_o$ sont les matrices de poids, $\mathbf{b}_1$, $\mathbf{b}_2$ et b_o les biais, et ReLU (Rectified Linear Unit) la fonction d'activation introduisant la non-linéarité essentielle. Cette architecture permet de capturer des interactions complexes entre caractéristiques via la propagation avant, tandis que la rétropropagation ajuste les paramètres pour minimiser l'erreur de prédiction.

E. Optimisation des Hyperparamètres

Pour chaque modèle, nous effectuons une recherche systématique des hyperparamètres optimaux :

— **KNN** : Méthode non-paramétrique fondée sur le principe de similarité locale. Pour chaque échantillon à prédire, l'algorithme identifie les k observations d'entraînement les plus proches selon une métrique de distance prédéfinie. La prédiction résulte ensuite d'une agrégation des valeurs cibles de ces voisins. La configuration optimale retenue après recherche exhaustive utilise $k = 11$ voisins avec une pondération inverse à la distance (‘weights='distance'‘) et la métrique de Manhattan (‘metric='manhattan', p=1‘), offrant une robustesse accrue aux échelles variables des caractéristiques tout en maintenant une précision locale optimale.

— **Random Forest** : L'optimisation du modèle Random Forest a été réalisée via une recherche systématique des hyperparamètres suivie d'une validation croisée rigoureuse. La configuration finale retenue après optimisation comprend 317 arbres de décision ('n-estimators=317') avec une profondeur illimitée ('max-depth=None'), permettant à chaque arbre de s'adapter pleinement à la complexité des données. Le paramètre 'min-samples-split=3' garantit qu'un nœud ne se divise que s'il contient au moins trois échantillons, prévenant ainsi le surapprentissage sur des patterns trop spécifiques. La stratégie 'max-features='log2'' sélectionne aléatoirement environ quatre caractéristiques ($\log_2(18) \approx 4$) à chaque division, favorisant la diversité des arbres. Le choix 'bootstrap=False' indique que chaque arbre est entraîné sur l'ensemble complet des données plutôt que sur des échantillons bootstrap, maximisant ainsi l'information disponible pour chaque décision.

— **MLP** : Architecture de réseau de neurones artificiels composée de couches denses interconnectées. Le modèle apprend des représentations hiérarchiques des données via une série de transformations non-linéaires. La configuration optimale obtenue après recherche aléatoire comprend deux couches cachées de tailles 128 et 64 neurones avec activation ReLU, un taux d'apprentissage constant, régularisation L2 de $\alpha = 0.001$, et l'optimiseur Adam pour 500 itérations maximales. Cette architecture permet de modéliser des relations complexes et non-linéaires entre les variables d'entrée et la cible tout en contrôlant le surapprentissage.

La sélection finale est basée sur la performance sur l'ensemble de validation, mesurée par le MAE.

IV. Résultats Expérimentaux

A. Performances Comparatives

Le tableau I présente les performances comparatives des différents modèles sur l'ensemble de test. Le Random Forest se distingue comme le modèle optimal avec un coefficient de détermination $R^2 = 0.821$ et une erreur absolue moyenne de 0.308 (échelle réelle). Cette performance supérieure s'explique par sa capacité à capturer des relations non-linéaires complexes tout en limitant le surapprentissage grâce à l'agrégation de multiples arbres de décision.

Table I
Comparaison des performances sur l'ensemble de test

Modèle	RMSE	MAE	R^2
Dummy (moyenne)	1.144856	0.906069	-0.000219
Régression Linéaire	0.667910	0.466952	0.659569
KNN	5.330366e-01	3.479302e-01	0.783176
Random Forest	**0.4844**	**0.3084**	**0.8210**
MLP	0.527195	0.347354	0.787902

B. Validation Croisée du Random Forest

Pour évaluer la stabilité du MLP, nous effectuons une validation croisée 5-fold. Les résultats (tableau II) montrent une faible variance entre les folds , confirmant la robustesse du modèle.

Table II
Résultats de validation croisée 5-fold du Random Forest

Fold	RMSE	MAE	R^2
1	0.506663	0.327159	0.813979
2	0.484107	0.309966	0.823568
3	0.487619	0.309985	0.821705
4	0.510256	0.316130	0.806732
5	0.483978	0.314636	0.818969
Moyenne	0.4945	0.3156	0.8170
Écart-type	0.0129	0.0070	0.0068

V. Discussion

A. Sélection du Modèle Optimal

Parmi les architectures évaluées, le Random Forest émerge comme le modèle optimal pour notre problème de prédiction immobilière. Cette sélection est justifiée par plusieurs caractéristiques distinctives de cette approche :

1) **Interprétabilité** : L'importance des caractéristiques est directement accessible via les mesures d'impureté des arbres, offrant des insights actionnables.
2) **Efficacité computationnelle** : L'entraînement est significativement plus rapide sans compromettre la précision.
3) **Robustesse** : Moins sensible à l'initialisation et aux hyperparamètres que le MLP.
4) **Déploiement** : Modèle plus léger et avec moins de dépendances logicielles.

B. Importance des Caractéristiques

L'analyse d'importance des caractéristiques du Random Forest révèle que le revenu médian (MedInc) est le prédicteur dominant, suivi de la caractéristique géographique synthétique (GeoAxis) et du nombre moyen de pièces (AveRooms). Cette hiérarchie correspond à l'intuition économique : le pouvoir d'achat local et la localisation sont les déterminants principaux des prix immobiliers.

C. Limitations et Biais Potentiels

1) Hétéroscédasticité Résiduelle

L'augmentation systématique des erreurs pour les propriétés haut de gamme suggère que le modèle capture moins efficacement les dynamiques de marché dans ce segment. Des approches alternatives telles que la régression quantile pourraient atténuer ce biais.

2) Données Temporellement Limitées

Le dataset date de 1990 et ne reflète pas les évolutions récentes du marché immobilier californien. Une extension avec des données historiques permettrait de modéliser les tendances temporelles.

3) Géocodage Approximatif

Dans l'application de déploiement, le géocodage via API peut introduire des imprécisions pour les localisations ambiguës. Une intégration avec des bases de données géographiques plus précises améliorerait la fiabilité.

D. Comparaison avec la Littérature

Nos résultats ($R^2 = 0.8210$) sont comparables ou supérieurs aux performances rapportées dans des études similaires utilisant le même dataset. Par exemple, Géron [11] rapporte un R^2 d'environ 0.82 avec un Random Forest optimisé, tandis que des approches par gradient boosting atteignent typiquement 0.85-0.87. La supériorité relative de notre implémentation peut être attribuée à l'ingénierie des caractéristiques avancée, en particulier la création de la caractéristique GeoAxis.

VI. Application de Déploiement

Une application web interactive a été développée avec Gradio pour rendre accessible la prédiction des prix immobiliers aux utilisateurs finaux. Cette interface permet aux utilisateurs de saisir les caractéristiques d'une propriété—nombre de pièces, chambres à coucher, âge de l'habitation, localisation géographique (ville et quartier), et nombre d'occupants—et d'obtenir une estimation du prix médian en temps réel. L'application intègre un processus complet de traitement, depuis la saisie jusqu'à la prédiction finale, garantissant à la fois simplicité d'utilisation et robustesse technique.

L'architecture de l'application suit un pipeline structuré en plusieurs étapes. D'abord, la localisation saisie (ville et quartier) est convertie en coordonnées géographiques (latitude, longitude) via l'API Geocodio. Ces coordonnées, combinées aux autres caractéristiques saisies, sont ensuite enrichies par le même processus d'ingénierie des caractéristiques utilisé lors de l'entraînement, incluant le calcul de la variable synthétique GeoAxis et des ratios démographiques. Les 18 caractéristiques résultantes sont normalisées avec le StandardScaler préentraîné, puis soumises au modèle Random Forest sérialisé. Enfin, la prédiction en échelle logarithmique est transformée en prix réel (en dollars) et présentée à l'utilisateur. L'application, déployée sous forme de serveur web Python léger, assure une latence inférieure à deux secondes et inclut des mécanismes de gestion d'erreurs pour garantir une expérience utilisateur fluide, même en cas d'entrées invalides ou d'indisponibilité temporaire des services externes.

VII. Conclusion et Perspectives

Cette étude a démontré l'efficacité d'une approche méthodologique rigoureuse pour la prédiction des prix immobiliers en Californie, où l'ingénierie systématique des caractéristiques—notamment la création de la variable synthétique GeoAxis et de ratios démographiques significatifs—a permis d'améliorer substantiellement les performances prédictives. Le modèle Random Forest optimisé, atteignant un coefficient de détermination $R^2 = 0.8210$, s'est révélé être la solution la plus équilibrée, alliant précision, interprétabilité et efficacité computationnelle. L'analyse des résidus a mis en lumière des patterns d'hétéroscédasticité persistants, tandis que le déploiement d'une application web interactive a validé l'applicabilité pratique de l'approche. Les perspectives futures incluent l'intégration de données temporelles, l'exploration d'architectures d'ensemble avancées, et l'extension géographique pour évaluer la généralisabilité des modèles, confirmant ainsi la pertinence des méthodologies de machine learning appliqué pour résoudre des problèmes économiques complexes.

Références

[1] F. Pedregosa et al., "Scikit-learn : Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[2] Scikit-learn Developers, "California Housing Dataset Documentation," 2023. [En ligne]. Disponible : https://scikit-learn.org/stable/datasets/real_world.html#california-housing-dataset

[3] R. K. Pace and R. Barry, "Sparse spatial autoregressions," *Statistics & Probability Letters*, vol. 33, no. 3, pp. 291–297, 1997.

[4] B. H. Baltagi and D. Li, "Predicting house prices using spatial data," *Empirical Economics*, vol. 35, no. 2, pp. 309–328, 2008.

[5] Z. Wang, R. C. K. Chan, and M. Zhang, "Machine learning approaches for housing price prediction : A comparative study," *Expert Systems with Applications*, vol. 113, pp. 240–251, 2018.

[6] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.

[7] T. K. Ho, "The random subspace method for constructing decision forests," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 20, no. 8, pp. 832–844, 1998.

[8] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967.

[9] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," *Nature*, vol. 323, no. 6088, pp. 533–536, 1986.

[10] R. Tibshirani, "Regression shrinkage and selection via the lasso," *Journal of the Royal Statistical Society : Series B (Methodological)*, vol. 58, no. 1, pp. 267–288, 1996.

[11] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, 2nd ed. O'Reilly Media, 2019. (Section 2 : "End-to-End Machine Learning Project")